Semana 3 - Actividad 1 / Limpieza de datos

Equipo 62

Ricardo Morales Bustillos - A01740032

Alejandro Jesús Vázquez Navarro - A01793146

Ciencia y analítica de Datos (Gpo 10)

Profesor: Dr. Jobish Vallikavungal Devassia

3 de octubre de 2022

Parte 1

1. Fundamentos de base de datos y para ciencia de datos

Debemos partir de la definición más pura: ¿qué es una base de datos? En el sentido más sencillo de la palabra, es una colección de listas que están organizadas por columnas. Estas listas las conoceremos como tablas que a su vez están conformadas por campos y por filas. Dicho de otro modo, una base de datos es una colección bien organizada de datos que guardan una relación perfectamente identificada. Las bases de datos son fundamentales para el funcionamiento crítico de cualquier compañía pues estarán orientadas (como gran colección) a una sola función de negocio. Es decir, podremos tener bases de datos orientadas a Recursos Humanos, Finanzas, Marketing, en fin, a cualquier función de negocio.

La ciencia de datos echa mano de las bases de datos para transformar datos crudos en información, posteriormente en conocimiento y en algunos estadíos más avanzados llegar hasta la sabiduría. Dicho lo anterior, la responsabilidad de un científico de datos será conocer tres grandes ámbitos de conocimiento: la parte matemática, la parte tecnológica y una vertical de negocio. En la convergencia de estos tres conjuntos encontramos a la Ciencia de Datos.

El punto más valiosos de todo este flujo de transformación (dato crudo, transformación en información y extracción de conocimiento) es la entrega de valor al negocio y convertirlo en accionables.

---

2. Fundamentos de almacenes de datos (Data Warehouse) para ciencia de datos

Derivado del gran crecimiento de información es necesario contar con un paradigma que permita acceder de manera rápida, confiable y organizada a la inforamción que los tomadores de decisiones necesitan. Es por esto, que Imonn y Kimball definieron dos grandes

aproximaciones para poder conformar una bóveda de datos. Por un lado tenemos la visión de Kimball donde los datamarts son creados primeros, después, a medida que son solicitados, estos se agregan al Data Warehouse. Immon al contrario, veía al Data Warehouse como un repositorio centralizado de información desde el momento cero de su concepción y por lo tanto almacena el dato desde su forma más atómica y granular posible.

Como científicos de datos debemos tener conocimiento en el manejo de Data Warehouse (datos estructurados o Bases de datos SQL) y en Data Lakes (bases de datos NoSql) ya que los desafíos constantes de la industria ya exigen estas competencias.

Es importante mencionar que no importando la aproximación que le demos a nuestro Data Warehouse, este siempre tendrá las siguientes características: debe contener datos históricos, no volátiles, datamarts enfocados a funciones específicas de negocio y debe estar integrado en una plataforma.

Parte 2

Limpieza y preparación de datos

In [1]:
```
# Importación de librerías necesarias para la lectura y tratamiento de dat

import pandas as pd
import numpy as np
```

In [2]:
```
# Lectura de los datos de ejercicio

df = pd.read_csv("https://raw.githubusercontent.com/PosgradoMNA/Actividade
df.head()
```

Out[2]:

	ID	X1	X2	X3	X4	X5	X6	X7	X8	X9	...	X15	X16	X17	X18	
0	1	20000	2.0	2.0	1.0	24.0	2.0	2.0	-1.0	-1.0	...	0.0	0.0	0.0	0.0	(
1	2	120000	2.0	2.0	2.0	26.0	-1.0	2.0	0.0	0.0	...	3272.0	3455.0	3261.0	0.0	1(
2	3	90000	2.0	2.0	2.0	34.0	0.0	0.0	0.0	0.0	...	14331.0	14948.0	15549.0	1518.0	1!
3	4	50000	2.0	2.0	1.0	37.0	0.0	0.0	0.0	0.0	...	28314.0	28959.0	29547.0	2000.0	2(
4	5	50000	1.0	2.0	1.0	57.0	-1.0	0.0	-1.0	0.0	...	20940.0	19146.0	19131.0	2000.0	36(

5 rows × 25 columns

In [3]:

```
# Asignación de cabeceras de acuerdo a la información proporcionada:

#X1: Amount of the given credit (NT dollar): it includes both the individu
#X2: Gender (1 = male; 2 = female).
#X3: Education (1 = graduate school; 2 = university; 3 = high school; 4 =
#X4: Marital status (1 = married; 2 = single; 3 = others).
#X5: Age (year).
#X6 - X11: History of past payment. We tracked the past monthly payment re
#X12-X17: Amount of bill statement (NT dollar). X12 = amount of bill state
#X18-X23: Amount of previous payment (NT dollar). X18 = amount paid in Sep

# Creo un diccionario con los nombres de las columnas
col_dictionary = {'X1':'given_credit',
                  'X2': 'gender',
                  'X3': 'education',
                  'X4': 'marital_status',
                  'X5': 'age',
                  'X6':'sep05_repayment',
                  'X7':'aug05_repayment',
                  'X8':'jul05_repayment',
                  'X9':'jun05_repayment',
                  'X10':'may05_repayment',
                  'X11':'abr05_repayment',
                  'X12': 'sep05_bill_statement',
                  'X13': 'aug05_bill_statement',
                  'X14': 'jul05_bill_statement',
                  'X15': 'jun05_bill_statement',
                  'X16': 'may05_bill_statement',
                  'X17': 'abr05_bill_statement',
                  'X18': 'sep05_previous_payment',
                  'X19': 'aug05_previous_payment',
                  'X20': 'jul05_previous_payment',
                  'X21': 'jun05_previous_payment',
                  'X22': 'mayu05_previous_payment',
                  'X23': 'abr05_previous_payment'
                  }

# Renombro las columnas para tener un mejor entendimiento del dataset
df.rename(columns = col_dictionary , inplace=True)

df.head()
#df.columns

```

Out[3]:

	ID	given_credit	gender	education	marital_status	age	sep05_repayment	aug05_repayment
0	1	20000	2.0	2.0	1.0	24.0	2.0	2.0
1	2	120000	2.0	2.0	2.0	26.0	-1.0	2.0
2	3	90000	2.0	2.0	2.0	34.0	0.0	0.0
3	4	50000	2.0	2.0	1.0	37.0	0.0	0.0
4	5	50000	1.0	2.0	1.0	57.0	-1.0	0.0

5 rows × 25 columns

In [4]:
```
# Guardo el dataframe en un archivo .csv para su posterior utillización

df.to_csv("my_data.csv", encoding="utf-8")

# Será importante almacenar la cantidad original de registros para entende

original_size_df = len(df)
print(f'El tamaño original del dataset es de {original_size_df}')
```

```
El tamaño original del dataset es de 30000
```

In [5]:
```
# Vamos a comenzar la verificación de la calidad del dato
# ¿Tenemos nulos tenemos?

df.isnull().values.any()


```

Out[5]:
```
True
```

In [6]:
```
# Sí tenemos, veamos en qué columnas
df.isnull().any()
```

Out[6]:
```
ID                          False
given_credit                False
gender                       True
education                    True
marital_status               True
age                          True
sep05_repayment              True
aug05_repayment              True
jul05_repayment              True
jun05_repayment              True
may05_repayment              True
abr05_repayment              True
sep05_bill_statement         True
aug05_bill_statement         True
jul05_bill_statement         True
jun05_bill_statement         True
may05_bill_statement         True
abr05_bill_statement         True
sep05_previous_payment       True
aug05_previous_payment       True
jul05_previous_payment       True
jun05_previous_payment       True
mayu05_previous_payment      True
abr05_previous_payment       True
Y                            True
dtype: bool
```

In [7]:
```
# Prácticamente en todas las columnas
```

In [8]:
```
# ¿Tenemos datos con na?
df.isna().any()
```

Out[8]:
```
ID                          False
given_credit                False
gender                       True
education                    True
marital_status               True
age                          True
sep05_repayment              True
aug05_repayment              True
jul05_repayment              True
jun05_repayment              True
may05_repayment              True
abr05_repayment              True
sep05_bill_statement         True
aug05_bill_statement         True
jul05_bill_statement         True
jun05_bill_statement         True
may05_bill_statement         True
abr05_bill_statement         True
sep05_previous_payment       True
aug05_previous_payment       True
jul05_previous_payment       True
jun05_previous_payment       True
mayu05_previous_payment      True
abr05_previous_payment       True
Y                            True
dtype: bool
```

In [9]:
```
# Excepto en ID y given_credit, prácticamente en todas las columnas existe
# Entonces, ¿qué podemos hacer?
# Como refiere la literatura, podemos descartar los valores faltantes:

df.dropna(inplace=True)
```

In [10]:
```
# Veamos cuántos datos tenemos en na

df.isna().values.any()

```

Out[10]:
```
False
```

In [11]:
```
# Prácticamente ninguno... ¿pero habrán sido muchos los descartados?

dismissed_rows = original_size_df- len(df)
print("Cuántas filas hay en el dataset:", len(df))
print(f"Perdimos {dismissed_rows} registros que equivale al  {(dismissed_r
```

```
Cuántas filas hay en el dataset: 29958
Perdimos 42 registros que equivale al  0.13999999999999999
```

In [12]:
```
# Recuperemos el dataframe original para hacer más pruebas

df2 = pd.read_csv("my_data.csv", encoding="utf-8")
dfOriginal = df2.copy()
# Hacemos una copia para poder analizar el dataframe original más adelante
df3 = df2.copy()

# Verificamos nuevamente la calidad del dataframe

df2.isna().any()
```

Out[12]:
```
Unnamed: 0                 False
ID                         False
given_credit               False
gender                      True
education                   True
marital_status              True
age                         True
sep05_repayment             True
aug05_repayment             True
jul05_repayment             True
jun05_repayment             True
may05_repayment             True
abr05_repayment             True
sep05_bill_statement        True
aug05_bill_statement        True
jul05_bill_statement        True
jun05_bill_statement        True
may05_bill_statement        True
abr05_bill_statement        True
sep05_previous_payment      True
aug05_previous_payment      True
jul05_previous_payment      True
jun05_previous_payment      True
mayu05_previous_payment     True
abr05_previous_payment      True
Y                           True
dtype: bool
```

In [13]:
```
# Una técnica interesante es eliminar columnas donde falte al menos un ele

df2.dropna(axis = 1, inplace=True)
```

In [14]:
```
# ¿Cuál es el resultado?

df2.head()

# ¡Solo tenemos 4 columnas! Esto claramente no nos va a ayudar a nuestros
# solamente aplicamos el criterio de eliminación si existe un na en una co

```

Out[14]:

	Unnamed: 0	ID	given_credit
0	0	1	20000
1	1	2	120000
2	2	3	90000
3	3	4	50000
4	4	5	50000

In [15]:
```
# Intenemos eliminar solo las filas donde hay elementos perdidos

df3.dropna(how = "all", inplace=True)

# Veamos
df3

# Tenemos 30k registros aún.
```

Out[15]:

	Unnamed: 0	ID	given_credit	gender	education	marital_status	age	sep05_repayment
0	0	1	20000	2.0	2.0	1.0	24.0	2.0
1	1	2	120000	2.0	2.0	2.0	26.0	-1.0
2	2	3	90000	2.0	2.0	2.0	34.0	0.0
3	3	4	50000	2.0	2.0	1.0	37.0	0.0
4	4	5	50000	1.0	2.0	1.0	57.0	-1.0
...	...	...	...	...	...	...	...	...
29995	29995	29996	220000	1.0	3.0	1.0	39.0	0.0
29996	29996	29997	150000	1.0	3.0	2.0	43.0	-1.0
29997	29997	29998	30000	1.0	2.0	2.0	37.0	4.0
29998	29998	29999	80000	1.0	3.0	1.0	41.0	1.0
29999	29999	30000	50000	1.0	2.0	1.0	46.0	0.0

30000 rows × 26 columns

In [16]:

```
# Es posible también aplicar umbrales para determinar cuántas filas elimin
# En el ejercicio se pide que mantengamos las filas con al menos 2 valores

dfAlMenos2Filas = df2.copy()
dfAlMenos2Filas.dropna(thresh =2 , axis=0, inplace=True)
dfAlMenos2Filas
```

Out[16]:

	Unnamed: 0	ID	given_credit
0	0	1	20000
1	1	2	120000
2	2	3	90000
3	3	4	50000
4	4	5	50000
...	...	...	...
29995	29995	29996	220000
29996	29996	29997	150000
29997	29997	29998	30000
29998	29998	29999	80000
29999	29999	30000	50000

30000 rows × 3 columns

In [17]:
```
# Definir en qué columnas podemos buscar valores faltantes

dfValoresFaltantes = dfOriginal.copy()
dfValoresFaltantes

dfValoresFaltantes.dropna(thresh = 5,
           axis = 1,
           inplace = True
           )
dfValoresFaltantes
```

Out[17]:

	Unnamed: 0	ID	given_credit	gender	education	marital_status	age	sep05_repayment
0	0	1	20000	2.0	2.0	1.0	24.0	2.0
1	1	2	120000	2.0	2.0	2.0	26.0	-1.0
2	2	3	90000	2.0	2.0	2.0	34.0	0.0
3	3	4	50000	2.0	2.0	1.0	37.0	0.0
4	4	5	50000	1.0	2.0	1.0	57.0	-1.0
...	...	...	...	...	...	...	...	...
29995	29995	29996	220000	1.0	3.0	1.0	39.0	0.0
29996	29996	29997	150000	1.0	3.0	2.0	43.0	-1.0
29997	29997	29998	30000	1.0	2.0	2.0	37.0	4.0
29998	29998	29999	80000	1.0	3.0	1.0	41.0	1.0
29999	29999	30000	50000	1.0	2.0	1.0	46.0	0.0

30000 rows × 26 columns

Solución 2

In [18]:
```
# Creamos una copia del dataframe original

miDataFrame = dfOriginal.copy()

```

In [ ]:
```

```

In [19]:
```
# Esta solución calcula el peso de la columna que seleccionemos con datos
# ¿Cuáles son las columnas con datos nulos?
miDataFrame.isna().any()

# Prácticamente todas
# Usaré para esta solución la librería pandas-profiling para tener una mej

from pandas_profiling import ProfileReport

profile = ProfileReport(miDataFrame)


```

In [20]:
```
#profile
```

Con base en este reporte, puedo determinar lo siguiente: ***given_credit*** fue la variable con mayor densidad pues no tiene valores perdidos y las variables siguientes son las que tienen el mayor número de datos nulos

- may05_bill_statement 17 missing

may05_bill_st...
Real number (ℝ)

HIGH CORRELATION
ZEROS

Distinct	21000	Minimum	-81334
Distinct (%)	70.0%	Maximum	927171
Missing	17	Zeros	3504
Missing (%)	0.1%	Zeros (%)	11.7%
Infinite	0	Negative	655
Infinite (%)	0.0%	Negative (%)	2.2%
Mean	40324.49398	Memory size	234.5 KiB

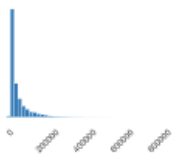

- abr05_repayment 14 missing

abr05_repaym...
Real number (ℝ)

HIGH CORRELATION
ZEROS

Distinct	10	Minimum	-2
Distinct (%)	< 0.1%	Maximum	8
Missing	14	Zeros	16278
Missing (%)	< 0.1%	Zeros (%)	54.3%
Infinite	0	Negative	10630
Infinite (%)	0.0%	Negative (%)	35.4%
Mean	-0.2911358634	Memory size	234.5 KiB

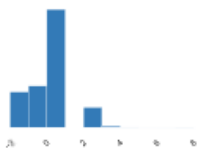

Toggle details

- sep05_bill_statement 11 missing

sep05_bill_sta...

Distinct	22718	Minimum	-165580

Real number (ℝ)

HIGH CORRELATION
ZEROS

Distinct (%)	75.8%
Missing	11
Missing (%)	< 0.1%
Infinite	0
Infinite (%)	0.0%
Mean	51236.86275

Maximum	964511
Zeros	2007
Zeros (%)	6.7%
Negative	590
Negative (%)	2.0%
Memory size	234.5 KiB

Toggle details

- jul05_bill_statement 13 missing

jul05_bill_stat...
Real number (ℝ)

HIGH CORRELATION
ZEROS

Distinct	22020
Distinct (%)	73.4%
Missing	13
Missing (%)	< 0.1%
Infinite	0
Infinite (%)	0.0%
Mean	47025.35015

Minimum	-157264
Maximum	1664089
Zeros	2868
Zeros (%)	9.6%
Negative	655
Negative (%)	2.2%
Memory size	234.5 KiB

- jun05_bill_statement 15 missing

jun05_bill_stat...
Real number (ℝ)

HIGH CORRELATION
ZEROS

Distinct	21541
Distinct (%)	71.8%
Missing	15
Missing (%)	< 0.1%
Infinite	0
Infinite (%)	0.0%
Mean	43275.65233

Minimum	-170000
Maximum	891586
Zeros	3194
Zeros (%)	10.6%
Negative	675
Negative (%)	2.2%
Memory size	234.5 KiB

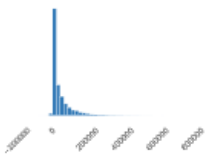

Toggle details

Así que puedo aplicar una técnica de media o mediana. Esto depende, si existen outliers, lo mejor será aplicar la mediana pues la media es altamente sensible a los outliers.

In [21]:
```
1 # may05_bill_statement es la columna con mayor cantidad de nulos
2 may05_bill_statement_median = miDataFrame.may05_bill_statement.median()
3 miDataFrame['may05_bill_statement'].fillna(value = may05_bill_statement_me
4
```

In [22]:
```
# Mismo caso para abr05_repayment, sep05_bill_statement, jul05_bill_statem

abr05_repayment_median = miDataFrame.abr05_repayment.median()
miDataFrame['abr05_repayment'].fillna(value = may05_bill_statement_median,

sep05_bill_statement_median = miDataFrame.sep05_bill_statement.median()
miDataFrame['sep05_bill_statement'].fillna(value = sep05_bill_statement_me

jul05_bill_statement_median = miDataFrame.jul05_bill_statement.median()
miDataFrame['may05_bill_statement'].fillna(value = jul05_bill_statement_me

jun05_bill_statement_median = miDataFrame.jun05_bill_statement.median()
miDataFrame['jun05_bill_statement'].fillna(value = jun05_bill_statement_me

```

No es necesario correr todo el profiler de pandas, puedo enfocarme solo en las columnas que imputé con mediana para revisar si en efecto ya no tienen datos nulos:

In [23]:
```
# Como se desmuestra, ya no existen valores nulos en las columnas mencionad

colsIniciales = ['abr05_repayment', 'sep05_bill_statement', 'may05_bill_st
miDataFrame[colsIniciales].isna().sum()


```

Out[23]:
```
abr05_repayment         0
sep05_bill_statement    0
may05_bill_statement    0
jun05_bill_statement    0
dtype: int64
```

In [24]:
```
# Es posible volver a correr el informe de datos llamando al dataframe tra

profileLimpio = ProfileReport(miDataFrame)

# No lo correré pero está la referencia

```

In [25]:
```
# Otro dato interesante es que faltan 3 datos en la columna dependiente Y
miDataFrame["Y"].isna().sum()


```

Out[25]:
```
3
```

In [26]:
```
1
2  # Veamos cuáles son y si vale la pena dejarlos o no.
3  miDataFrame[miDataFrame["Y"].isna()]
4
5  #Observamos que todas las variables de pagos anteriores no tienen pago y l
6  #No ofrece valor al modelo y se eliminará
7
8  miDataFrame =miDataFrame.dropna(subset=['Y'])
9
10 #Volvemos a correr miDataFrame["Y"].isna().sum() para saber si quedaron al
11 miDataFrame["Y"].isna().sum()
12
13 # El resultado es 0.
```

Out[26]: 0

Parte 3

Con base en los resultados de tu libreta de Google Colab de la Parte 2 responde detalladamente las siguientes preguntas:

¿Qué datos considero mas importantes?* ¿Por qué?

De acuerdo al análisis realizado, las columnas (o características) más importantes fueron:

1. given_credit,
2. education,
3. gender,
4. age,
5. marital_status

Esto debido a que registraron el menor número de datos perdidos. Inclusive, given_credito (incluyendo *ID*) fue la característica con cero valores nulos. Las variables demográficas registraron menor cantidad de datos perdidos que las variables que registraban la amortización del crédito.

¿Se eliminaron o reemplazaron datos nulos? ¿Qué se hizo y por qué?

Después del análisis realizado con pandas profile, se encontró que las siguientes variables contenían el mayor número de nulos:

1. may05_bill_statement **17 missing**
2. abr05_repayment **14 missing**
3. sep05_bill_statement **11 missing**
4. jul05_bill_statement **11 missing**
5. jun05_bill_statement **11 missing**

Siendo variables numéricas y después de analizar que existían outliers en ellas, se determinó que la mejor técnica de imputación de datos era aplicar la mediana para cada una de ellas, recordando que esta métrica no es sensible a los outliers.

¿Es necesario ordenar los datos para el análisis? Sí / No / ¿Por qué?

Depende, si se van a realizar agregados por columnas aplicando funciones escalares (sum, max, min, std, count) entonces sí es necesario ordenar para determinar qué grupo de elementos registra la métrica con mayor o menor valor.

Si solamente haremos cálculo de nulos, eliminar filas o columnas, entonces no es necesario ordenar los datos. No infiere esta operación en el resultado final.

¿Existen problemas de formato que deban solucionar antes del proceso de modelado? Sí / No / Por qué.

La respuesta corta definitivamente es SÍ. Particularmente en este caso nos encontramos con el problema de las cabeceras. Los nombres de las columnas estaban en modo canónico y no semántico. Esto hace muy difícil poder identifcar el valor semántico de cada columna. El ejercicio incluía los nombres de las columnas y su cardinalidad, i.e la primera columna corresponde al Identificador, la segunda al crédito, etc. Gracias a esta asignación pudimos trabajar de manera más sencilla el análisis y evitamos confusiones posteriores. Caer en este tipo de errores es muy frecuente cuando se realizan análisis exploratorios de datos sin contar con un diccionario de datos.

¿Qué ajustes se realizaron en el proceso de limpieza de datos (agregar, integrar, eliminar, modificar registros (filas), cambiar atributos (columnas)?

Considerando en análisis realizado gracias al profiler de pandas, fue posible identificar variables de amortización con datos nulos. Estos datos son altamente sensibles para poder determinar el nivel de morosidad de un cliente. Entonces era importante realizar una imputación de datos.

La técnica elegida fue imputar la mediana para evitar que la media pudiera sesgar el modelado.

Algo notable también fue eliminar algunas filas que tenían la variable dependiente Y en nulo y además no tenían datos para los pagos anteriores, al ser solamente 3, se determinó que lo mejor era quitar esas filas del modelo. Un caso diferente hubiera sido si esos 3 datos hubieran

In [ ]:
```
1
```

In [ ]:
```
1
```

Type *Markdown* and LaTeX: α^2